

Домашнє завдання: Перший Data Pipeline в AWS

Фаза 0: Підготовка та фінансова безпека

1. Створення акаунту:

- Зареєструйтеся на [AWS Free Tier](#). Вам знадобиться пошта та банківська картка.
- **Важливо по карті:** Рекомендую використовувати **віртуальну картку** Монобанк з нульовим або мінімальним балансом (\$1-2 для верифікації). Це гарантує, що ви не вийдете за межі безкоштовного ліміту.

2. Billing Alarm:

- Перейдіть у сервіс **CloudWatch** -> **Alarms**.
- Створіть аларм: **Metric: Estimated Charges > \$1**.
- Налаштуйте сповіщення на свою пошту (через SNS). Поки ви не отримаєте на емейл лист-підтвердження про підписку на аларм — завдання не вважається початим.

Фаза 1: Identity & Access Management (IAM)

Root-акаунт — не використовуємо!

1. Зайдіть у сервіс **IAM**.
2. Створіть нового користувача (наприклад, `aws_admin`, `data_engineer_Andrii`).
3. Додайте йому права: приєднайте політику `AdministratorAccess`.
4. Згенеруйте пароль та обов'язково увімкніть **MFA**.
5. **Вийдіть із Root-акаунту** і залогіньтесь як створений користувач. Це База

Фаза 2: Побудова Data Lake (S3 -> Glue -> Athena)

1. S3: Зберігання

- Створіть бакет у сервісі **S3** (ім'я має бути унікальним у всьому світі).
- Завантажте будь-який CSV-файл. Візьміть датасет на Kaggle або створіть файл вручну.

2. IAM Role: Доступи

- Щоб сервіс **Glue** міг прочитати ваш файл у S3, йому потрібна роль.
- Створіть роль для сервісу Glue з політиками: [AmazonS3FullAccess](#) та [AWSGlueServiceRole](#).

3. Glue Crawler: Автоматизація

- Йдіть у **AWS Glue -> Crawlers**.
- Налаштуйте Кравлер: вкажіть шлях до папки в S3 та виберіть створену раніше роль.
- Запустіть Кравлер ([Run Crawler](#)). Зачекайте хвилину, поки статус не зміниться на [Completed](#).
- Перевірте вкладку **Tables**: там має з'явитися таблиця, яку AWS створив сам, вгадавши типи колонок.

4. Athena: Аналітика

- Перейдіть у сервіс **Athena**.
- Виберіть свою базу даних та таблицю.
- Виконайте SQL-запит: [SELECT * FROM your_table_name LIMIT 10;](#).
- *Примітка:* Якщо Athena просить налаштувати [S3 output location](#) — створіть ще одну папку в S3 для результатів запитів.

Фаза 3: Для Linux та CLI (Optional)

Якщо ви не хочете реєструвати карту в AWS, ви можете використати **LocalStack**.

- Встановіть **Docker** та **LocalStack** на свою Ubuntu.
- Запустіть контейнер: `localstack start`.
- Використовуйте **AWS CLI** для імітації тих самих кроків:
- Bash

```
aws --endpoint-url=http://localhost:4566 s3 mb s3://test-bucket
```

```
aws --endpoint-url=http://localhost:4566 s3 cp data.csv s3://test-bucket
```

Вимоги до здачі завдання

Надішліть один PDF-файл, що містить наступні 5 підтверджень вашої роботи:

1. **Скріншот 1:** Активний аларм у CloudWatch на суму \$1.
2. **Скріншот 2:** Скріншот завантаженого файлу у S3 Бакет.
3. **Скріншот 3:** Список користувачів у IAM (має бути видно вашого адміна).
4. **Скріншот 4:** Таблиця у Glue Catalog, яку створив кравлер (має бути видно структуру колонок та типів даних).
5. **Скріншот 5:** Вікно результатів Athena з даними, які ви дістали з файлу.

Порада від лектора: Документація AWS виглядає велетенською але вона дійсно корисна і добре структурована. Там є відповіді на всі питання — від лімітів до бест-практис побудови пайплайнів. Якщо щось не виходить з першого разу — це нормально. Це хмара, тут вчать на помилках (бажано, на безкоштовних).